
# 文字探勘實作 - NER David Chiu

# 命名實體識別

# 命名實體識別(Named Entity Recognition)

■ 從一段自然語言文本中找出相關實體,並標註出其位置以及類型



#### 為什麼要做 NER?

- ■字典比對方法
  - □建立一字典,並比對斷詞過的文章中是否有該關鍵字詞

■範例

org = ['台積電']


import jieba

set(org) & set(list(jieba.cut('今、明年資本支出近兆台積電大擴產商機來了')))

# 但如果有同義詞出現?

- 台積電也可以被稱作 TSMC, 台積
  - □e.g. 台積鉅額交易爆萬張大量
- ■解決方案
  - 建立同義辭典(耗工費時)
  - 做命名實體識別(Named Entity Recognition)

# NER研究進展



## 序列標注方法

- ■在基於機器學習的方法中,NER被當作是序列標註問題
- 序列標註問題中當前的預測標籤不僅與當前的輸入特徵相關,還與 之前的預測標籤相關,即預測標籤序列之間是有強相互依賴關係



#### 序列標注問題

- I come from New York
  - ■對應的標註是: OOOB-loc I-loc O
  - ■New York 標示成 B-loc I-loc,B表示開頭,I表示之後的字,loc代表自己定義entity的類別
- I come from Taiwan
  - 對應的標註是:OOOB-loc O


使用者可以自訂所需要的entity

#### NER 方式

- ■任務簡單或訓練資料量很少,用正則表達式或直接比對資料庫
- 如果訓練資料量夠多的話就可以用:HMM或CRF
- HMM 或 CRF 都可以寫成Evaluation 與 Inference 兩個步驟
  - □Evaluation:定義F(x,y), x代表輸入序列, y代表輸出序列, F(x,y)代表好壞程度, 值越大代表y越符合我們的需要
  - □Inference:在所有可能的y集合裡找到一組y能最大化F(x,y)的值

## 隱馬爾可夫模型

- ■用來描述一個含有隱含未知參數的馬爾可夫過程
- ■目的是從可觀察的參數中確定該過程的隱含參數。然後利用這些參 數來作斷詞



# 誰是馬可夫?

Andrey Markov (14 June 1856 N.S. – 20 July 1922)

Calculated letter sequences of the Russian language



# 問題描述

■ States -> "F", "L"


#### ■ Transition Matrix

|        | Fair | Loaded |
|--------|------|--------|
| Fair   | 0.95 | 0.05   |
| Loaded | 0.1  | 0.9    |

#### **■** Emission Matrix


| Fair | Loaded                   |  |
|------|--------------------------|--|
| 1/6  | 1/10                     |  |
| 1/6  | 1/10                     |  |
| 1/6  | 1/10                     |  |
| 1/6  | 1/10                     |  |
| 1/6  | 1/10                     |  |
| 1/6  | 1/2                      |  |
|      | 1/6<br>1/6<br>1/6<br>1/6 |  |

# **Problem Description**




# Algorithm


Given Observable Sequence: 6,6,1,5,3,2...



# Start to Step 1




# Step 1 to Step 2




P\_OldState(State) \*P\_Trans(Old\_State -> New\_State)\* P\_Observe(6 | New\_State)

# **Most Likely Path**




# Step 2 to Step 3




P\_OldState(State) \*P\_Trans(Old\_State -> New\_State)\* P\_Observe(1 | New\_State)

# **Most Likely Path**



P\_OldState(State) \*P\_Trans(Old\_State -> New\_State)\* P\_Observe(1 | New\_State)

#### **Path Construction**



State Sequence: Loaded, Loaded, Loaded

#### **HMM**

```
x: John saw the saw.

y: start \rightarrow PN \rightarrow V \rightarrow D \rightarrow N \rightarrow end

P(x,y)=P(y)P(x|y)
P(y)=P(PN|start) \qquad P(x|y)=P(John|PN)
\times P(V|PN) \qquad \times P(saw|V)
\times P(D|V) \qquad \times P(the|D)
\times P(N|D) \qquad \times P(saw|N)
```

- P(y)裡的每一項可以由訓練數據統計得到,這裡我們會得到一個N維向量代表Start Probability
- N\*N的矩陣代表Transition Probability
- (x|y)代表有了這個標註後,產生這個詞的機率,也可以由統計後得到,寫成N\*M的矩陣代表 Emission Probability代表有多少種類別標籤

#### **HMM** Inference

■用 Viterbi 演算法窮舉所有的y

$$\tilde{y} = arg \max_{y \in \mathbb{Y}} P(x, y)$$

■ 選出最高的 y 當成標注結果

# 條件隨機域(CRF)

- CRF中的特徵向量,接受四個參數:
  - □句子s(就是我們要標註詞性的句子)
  - □i,用來表示句子s中第i個單詞
  - □I\_i,表示要評分的標註序列給第i個單詞標註的詞性
  - □I\_i-1,表示要評分的標註序列給第i-1個單詞標註的詞性
- 它的輸出值是0或者1,0表示要評分的標註序列不符合這個特徵,1 表示要評分的標註序列符合這個特徵。

# 條件隨機域(CRF)

定義好一組特徵函數後,我們要給每個特徵函數f\_j賦予一個權重λ\_j。現在,只要有一個句子s,有一個標註序列I,我們就可以利用前面定義的特徵函數集來對I評分

$$score(l|s) = \sum_{j=1}^{m} \sum_{i=1}^{n} \lambda_j f_j(s,i,l_i,l_{i-1})$$

求每一個特徵函數f\_j評分值的和

求句子中每個位置的單詞的的特徵值的和

# CRF 範例(1)

$$f_1(s,i,l_i,l_{i-1})=1$$

■當I\_i是"副詞"並且第i個單詞以"ly"結尾時,我們就讓f1 = 1,其他情況f1為0

■f1特徵函數的權重λ1應當是正的。而且λ1越大,表示我們越傾向於採用那些把以"ly"結尾的單詞標註為"副詞"的標註序列

# CRF 範例(2)

$$f_2(s,i,l_i,l_{i-1})=1$$

- 如果i=1,I\_i=動詞,並且句子s是以"?"結尾時,f2=1,其他情況 f2=0
- λ2應當是正的,並且λ2越大,表示我們越傾向於採用那些把問句的第一個單詞標註為"動詞"的標註序列。

# CRF 範例(3)

$$f_3(s,i,l_i,l_{i-1})=1$$

■當 $I_i$ -1是介詞, $I_i$ 是名詞時,f3 = 1,其他情況f3 = 0。 λ3也應當是正的,並且λ3越大,說明我們越認為介詞後面應當跟一個名詞

# CRF 範例(4)

$$f_4(s,i,l_i,l_{i-1}) = 1$$

■ I\_i和I\_i-1都是介詞,那麼f4等於1,其他情況f4=0。這裡,我們應當可以想到λ4是負的,並且λ4的絕對值越大,表示我們越不認可介詞後面還是介詞的標註序列。

# 條件隨機域(CRF)

$$score(l|s) = \sum_{j=1}^m \sum_{i=1}^n \lambda_j f_j(s,i,l_i,l_{i-1})$$
 求每一個特徵函數 $f$ \_i評分值的和


■ 建條件隨機場,我們首先要定義一個特徵函數集,每個特徵函數都以整個句子s,當前位置i,位置i和i-1的標籤為輸入。然後為每一個特徵函數賦予一個權重,然後針對每一個標註序列I,對所有的特徵函數加權求和,也可以把求和的值轉化為一個概率值

# CRF與HMM的比較

- HMM 可以視為 CRF的特殊類型
- HMM模型中,當前的單詞只依賴於當前的標籤,當前的標籤只依賴於前一個標籤。只能定義局部性的特徵函數
- ■CRF卻可以著眼於整個句子s定義更具有全局性的特徵函數

## 神經網路方法

■ CRF, HMM 等方法,還是需要定義出特徵,使用深度學習方法可以直接實現End-to-end Learning



# 深度學習方法與 CRF 方法的比較

■深度學習方法並沒有一定的優勢

| 模型/实体类型↩         | 地名↩  | 组织↩   | 人名↩        |
|------------------|------|-------|------------|
| BILSTM+softmax ◆ | 85%← | 70%←  | 81%        |
| BILSTM+CRF←      | 84%← | 85%←  | 91%        |
| 作者(40轮)←         | 91%  | 85%◆3 | 87%←       |
| CRF++ <b>←</b>   | 91%← | 85%←  | 86%以子 @陈海斌 |

# NER 實作


#### **NLTK**

```
import nltk
from nltk.tokenize import word_tokenize
from nltk.tag import pos_tag
sent = nltk.word_tokenize(sent)
sent = nltk.pos_tag(sent)
sent = preprocess(ex)
sent
```

再利用詞性萃取出專有名詞

# Spacy

■工業級文字處理工具



#### Spacy

■ SpaCy的命名實體識別已經在OntoNotes 5語料庫上進行了訓練,它支持以下實體類型

| TYPE        | DESCRIPTION  |
|-------------|--|
| PERSON      | People, including fictional.                         |
| NORP        | Nationalities or religious or political groups.      |
| FAC         | Buildings, airports, highways, bridges, etc.         |
| ORG         | Companies, agencies, institutions, etc.              |
| GPE         | Countries, cities, states.                           |
| LOC         | Non-GPE locations, mountain ranges, bodies of water. |
| PRODUCT     | Objects, vehicles, foods, etc. (Not services.)       |
| EVENT       | Named hurricanes, battles, wars, sports events, etc. |
| WORK_OF_ART | Titles of books, songs, etc.                         |
| LAW         | Named documents made into laws.                      |
| LANGUAGE    | Any named language.                                  |
| DATE        | Absolute or relative dates or periods.               |
| TIME        | Times smaller than a day.                            |
| PERCENT     | Percentage, including "%".                           |
| MONEY       | Monetary values, including unit.                     |
| QUANTITY    | Measurements, as of weight or distance.              |
| ORDINAL     | "first", "second", etc.                              |
| CARDINAL    | Numerals that do not fall under another type.        |

# Entity(命名)

```
import spacy
from spacy import displacy
from collections import Counter
import en_core_web_sm
nlp = en_core_web_sm.load()
```

doc = nlp('European authorities fined Google a record \$5.1 billion on
Wednesday for abusing its power in the mobile phone market and ordered the
company to alter its practices')
pprint([(X.text, X.label\_) for X in doc.ents])


# 列出標記

# pprint([(X, X.ent\_iob\_, X.ent\_type\_) for X in doc])

| TAG    | DESCRIPTION                              |
|--------|--|
| B EGIN | The first token of a multi-token entity. |
| IN     | An inner token of a multi-token entity.  |
| L AST  | The final token of a multi-token entity. |
| U NIT  | A single-token entity.                   |
| O UT   | A non-entity token.                      |


#### 視覺化呈現標記

displacy.render(nlp(str(sentences[20])), jupyter=True, style='ent')



## ckiptagger

- ■中研院開源出來的切詞套件
  - □https://github.com/ckiplab/ckiptagger



# ckiptagger

#### ■切詞準確度最高

| Tool             | (WS) prec | (WS) rec | (WS) f1 | (POS) acc |
|------------------|-----------|----------|---------|-----------|
| CkipTagger       | 97.49%    | 97.17%   | 97.33%  | 94.59%    |
| CKIPWS (classic) | 95.85%    | 95.96%   | 95.91%  | 90.62%    |
| Jieba-zh_TW      | 90.51%    | 89.10%   | 89.80%  |           |

- ■支援 POS, 切詞與NER 功能
- GNU General Public License v3.0

# Ckiptagger 範例

```
from ckiptagger import data_utils, construct_dictionary, WS, POS, NER
ws = WS("./data")
                   常要先下載資料
pos = POS("./data")
ner = NER("./data")
sentence list = [
   "全聯福利中心強力推出「PX Pay」行動支付後,更進一步開放8家銀行的實體信用卡、33家金融機構金融卡、3大
電子票證、3大國際行動Pay與台灣Pay等交易。同時釋出8大銀行刷卡優惠,其中聯邦卡首刷500元送1,000點福利點最高
,平日則以國泰世華天天消費滿500元送300點最強。",
word_sentence_list = ws(
   sentence list,
pos_sentence_list = pos(word_sentence_list)
entity sentence list = ner(word sentence list, pos sentence list)
```

# THANK YOU